英文文献编辑与编译码系统

学　　号_19071026_

姓　　名__周晟颐__

指导教师__杜永萍__

2021 年 12 月

1. 需求分析

1.1 基本要求

1.1.1

设计图形界面，可以实现英文文章的编辑与检索功能。

1.1.2

编辑过程包括：

（1）创建新文件；打开文件；保存文件。

（2）查找：输入单词在当前打开的文档中进行查找，并将结果显示在界面中。

（3）替换：将文章中给定的单词替换为另外一个单词，再保存等。

1.1.3

对于给定的文章片段（30<单词数量<100），统计该片段中每个字符出现的次数，然后以它们作为权值，对每一个字符进行编码，编码完成后再对其编码进行译码。在图形界面中演示该过程。

1.1.4

对于给定的多篇文章构成的文档集中，统计不同词汇的出现频率，并进行排序，在界面中显示 TOP 30 的排序结果。

1.1.5

对于给定的多篇文章构成的文档集中，建立倒排索引，实现按照关键词的检索（包括单个关键词；或者 2 个及以上关键词的联合检索，要求检索结果中同时出现所有的关键词），并在界面中显示检索的结果（如：关键词出现的文档编号以及所在的句子片段，可以将关键词高亮显示）

1.2 扩展要求

1.2.1

界面设计的优化。

1.2.2

对于编码与译码过程，可以自行设计其他算法。

1.2.3

高级检索，采用逻辑表达式来表示检索需求，例如：(关键词 A) AND (关键词 B) OR (关键词 C) AND (!关键词 D)

1.2.4

优化检索，对于检索结果的相关性排序，例如：包含关键词的数量等信息为依据。

1.2.5

可以自行根据本题目程序的实际应用情况，扩展功能。

1.3 需要处理的数据

1.3.1 英文文本

多个 txt 文档的导入，主要是文件路径，然后对文档中的内容进行处理。首先读取文本。

然后统计单词、字符的频率以及位置，生成索引；或者直接进行查找等功能。

1.3.2 用户输入的字符串

有多个功能需要用户输入字符串，比如创建新的文档需要命名、搜索单词、修改文档、在文档中替换内容。

1.3.3 网络爬取的信息

从网站上爬取单词翻译信息，包括 HTML 页。

1.3.4 选择的文档信息

用户通过“导入文件”，通过窗口选择并导入文档。

1.4 程序开发运行选用的环境

Python 3.9.1 64 bit

1.5 用户界面的设计

使用 PyQt5 库设计用户界面；主要窗口及功能如下：

main_UI：进入程序的 MainWindow，用来导入文件、搜索关键字等。

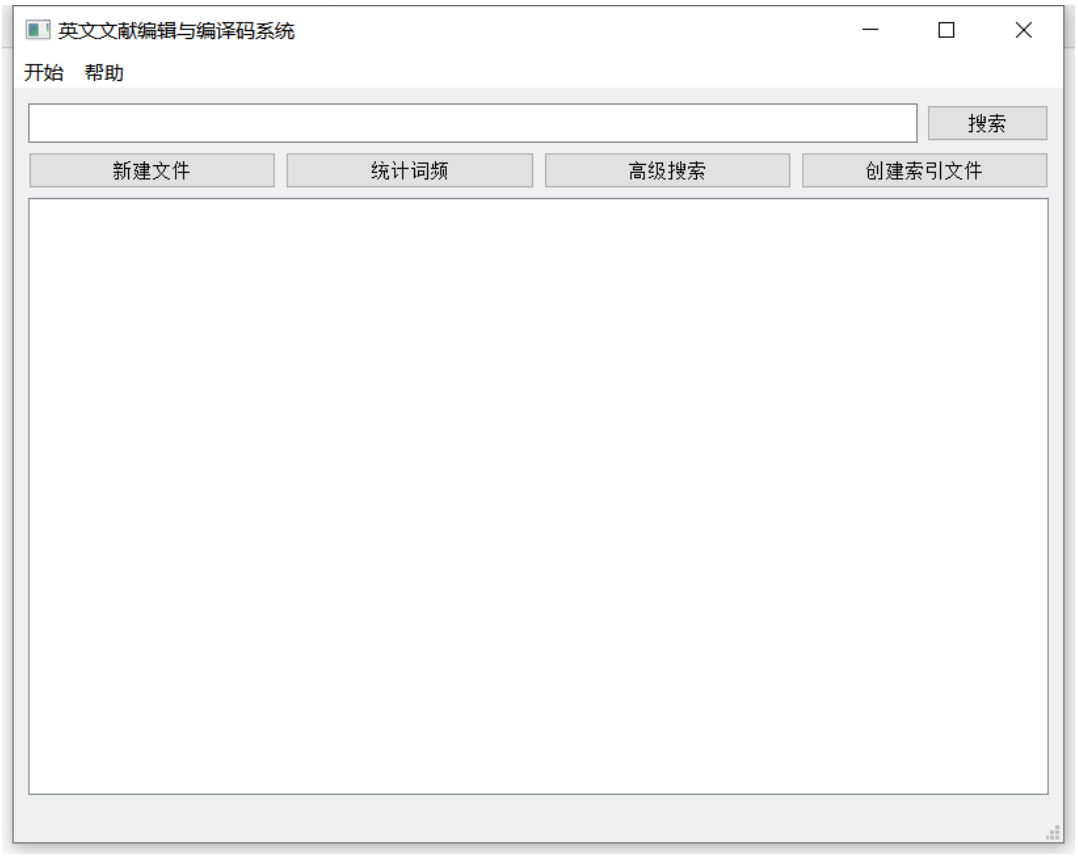

item_UI：从 main_UI 进入。主体为显示文章的文本框，同时有多个功能按钮。

search_UI：从 item_UI 进入。可以实现搜索、替换、计数等功能。

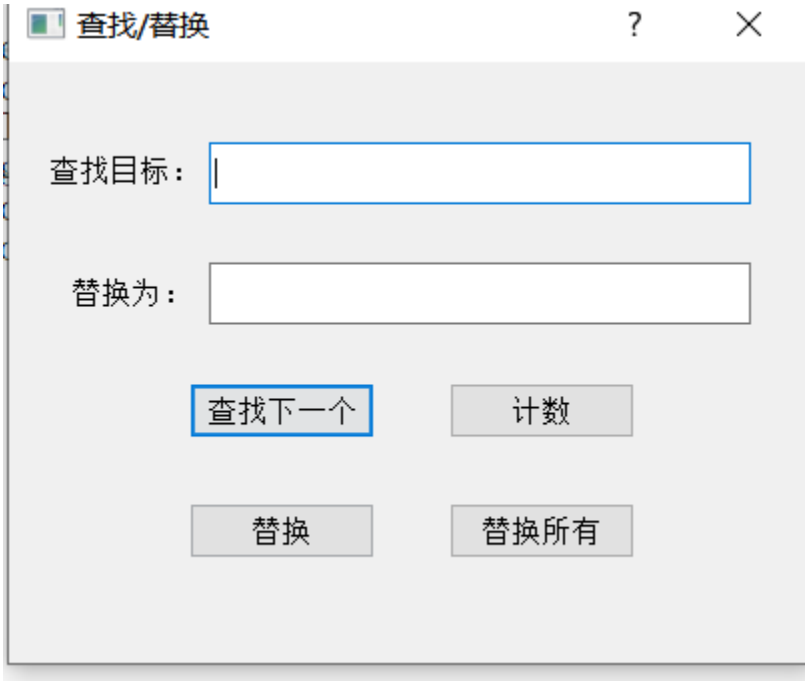

create_file_UI:从 main_UI 进入。可以创建新文件。

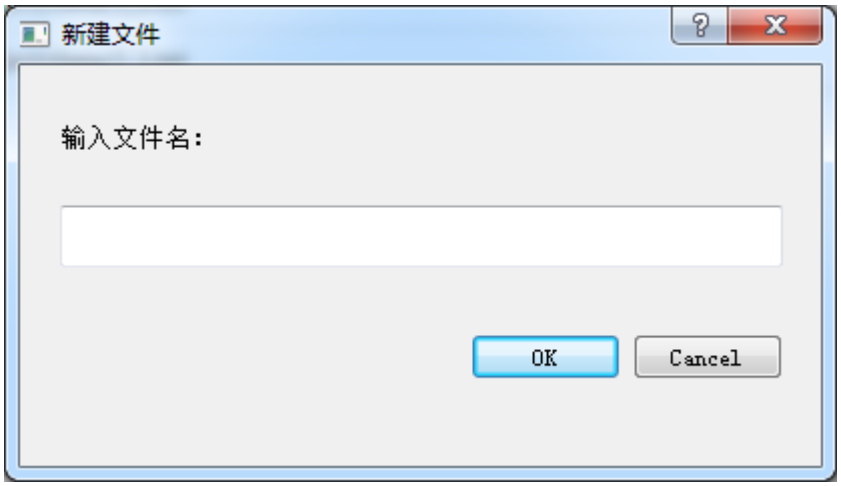

file_UI:从 main_UI 进入。可以导入文件。

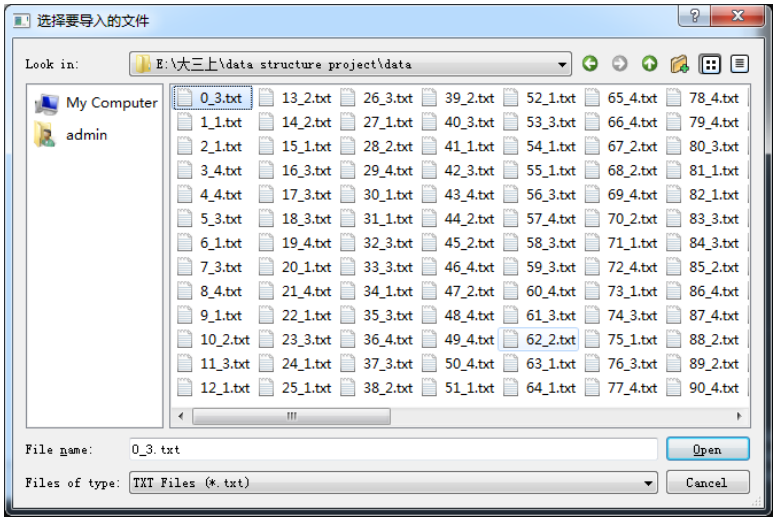

huffman_UI:从 item_UI 进入。可以显示 Huffman 编码的具体情况。

	字符	出现次数	编码
1	s	4	0011110
2	t	50	1100
3	o	34	0100
4	r	38	1000
5	y	14	101111
6	f	15	00001
7	a	46	1010
8	m	15	00100
9	n	37	0111
10	w	5	0110101
11	h	21	10110
12	s	30	0001
13	u	20	10010

progressbar_UI:进度条。

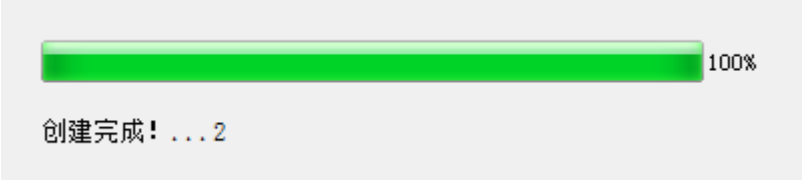

2. 数据结构设计

2.1 所定义主要的数据结构

2.1.1 Python 内置结构

（1）list

进行列表建立，以及一些需要排序的操作，其他大部分数据结构无法排序，需要先转化成 list，做排序再考虑转化回去，或者直接进行操作。用[]表示。

（2）dict

进行词典建立，使用键-值（key-value）存储，具有极快的查找速度，用于在不同目录下查找文本，不同文本下查找单词位置的功能，用牺牲空间的方式加快查找速度。用{}表示。

（3）tuple

与列表一样，也是一种序列，唯一不同的是元组不能被修改。用()表示。

2.1.2 哈夫曼树

给定 n 个权值作为 n 个叶子结点，构造一棵二叉树，若带权路径长度达到最小，称这样的二叉树为最优二叉树，也称为哈夫曼树(Hufffman Tree)。哈夫曼树是带权路径长度最短的树，权值较大的结点离根较近。本次构建的哈夫曼树的权值是文章中出现的所有字符的频率。并由此生成每个字符的编码，频率越高，其叶子结点距根越近，对应的编码也就越短。

2.1.3 索引结构

构建倒排索引，用来更快更方便的搜索单词或统计频率。索引结构如下：

[(word1,[文件位置])(word2,[文件位置])…]

2.2 程序整体结构以及各模块的功能描述

- main.py：总的 main 启动文件
- KMP.py:
  - def get_next(p)：寻找前缀后缀最长公共元素长度，计算字符串 p 的 next 表

- def kmp(s, p)：核心计算函数，返回字符串 p 的位置下标
- def positions(string, pattern)：查找 pattern 在 string 所有的出现位置的起始下标
- def count(string, pattern)：计算 pattern 在 string 的出现次数

- Huffman.py
  - class Node:
    - def __init__(self, freq)：初始化属性 left, right, father, freq
    - def isLeft(self)：返回该节点是否是父节点的左节点
    - def create_Nodes(freqs)：根据频率表创建叶子结点
    - def create_Huffman_Tree(nodes)：根据频率大小，使用队列创建哈夫曼树
    - def Huffman_Encoding(nodes, root)：用哈夫曼树生成哈夫曼对照表
    - def cal_count_freq(content)：计算字符频率
    - def cal_Huffman_codes(char_freqs)：整合上述 functions
- File.py
  - def search(files, keyword)：用 KMP 算法搜索计算所有传入的文件中 keyword 的数量，返回有序的文件及数量列表
  - def cal_words_freq(files, reverse=True)：用 KMP 算法搜索计算所有传入的文件中所有单词各自的数量，返回有序的文件及单词列表及数量
  - def cal_words_positions(files)：用 KMP 算法搜索计算所有传入的文件中所有单词各自的位置，返回有序的文件及单词列表及位置
  - class File:
    - def __init__(self, file_pos)：初始化函数，传入文件路径作为属性
    - def get_content(self)：获得文件内容
    - def set_content(self, content)：将文件内容修改为 content
    - def get_apperance_num(self, word)：统计文件内容中 word 出现的次数
    - def get_huffman_codes(self)：获得哈夫曼编码表
    - def get_encodeStr(self)：获得文件内容通过哈夫曼编码表编码后的字符串
    - def get_decodeStr(self, huffmanStr)：通过哈夫曼编码表将编码转换成原字符串
- main_UI.py
  - class UI:
    - def __init__(self)：构造函数，将属性 search_status 和 freqs 初始化
    - def init(self)：设置事件触发
    - def add_files(self)：调用 PyQt5 的 FileDialog 选择要添加的文件
    - def about(self)：“关于”窗口
    - def create_file(self)：创建文本文档，并添加文件
    - def cal_words_freqs(self)：调用 Cal_Words_Freq.py 中的函数统计词频并生成显示降序列表
    - def logic_search(self)：实现扩展功能中的高级搜索
    - def packaging(self)：调用 Inverted_Index.py 中的函数生成索引文件，并保存为 txt 文件

        - def clear_list(self)：清空文件列表
        - def get_research_content(self)：获得用户输入的需要检索的内容
        - def get_files_from_table(self)：获得当前文件列表
        - def creat_tableWidget(self, files, nums=[], poss=[])：在 GUI 中生成列表及相关信息
        - def creat_tableWidget1(self, files, nums=[])：在 GUI 中生成列表及相关信息
        - def closeEvent(self, event)：窗口关闭时出发的关闭事件
        - def search(self)：根据索引查找多个单词或词组，并显示频率及位置信息
        - def buttonClicked(self)：在底部状态栏显示相关信息
        - def itemClicked(self, row, col)：文件表单项目点击事件，打开新的 item 窗口
- item_UI.py
    - class item_UI
        - def __init__(self, file_pos, keyword=None, keyword1=None)：初始化，将属性 file 初始化为 file_pos，同时高亮 keyword/keyword1
        - def init(self, keyword, keyword1, filename)：连接按钮点击事件
        - def highlight(self, pattern, color=”yellow”)：将所有 pattern（以’;’分隔）做黄色高亮处理
        - def highlight1(self, pattern, color=”yellow”)：将所有 pattern 做黄色高亮处理
        - def hightlight_specific(self, pos=(0, 0), color=”gray”)：按位置高亮
        - def encode(self)：调用 self.file.get_encodeStr()显示编码
        - def decode(self)：调用函数进行译码
        - def huffman_codes(self)：显示哈夫曼编码表
        - def edit(self)：将文本框控件变为可编辑
        - def save(self)：将文本框中的文本保存到文件中
        - def search_substitute(self)：打开新窗口，查找或替换
        - def translate(self)：翻译所选文本
- about_UI.py：“关于”窗口
- freq_UI.py：显示表单的窗口。用来显示词频统计
- huffman_UI.py：显示表单的窗口。用来显示哈夫曼表
- file_UI.py：用来选择文件的窗口
- create_file_UI.py：新建文档的窗口
- progressbar_UI.py：进度条窗口
- search_UI.py
    - class search_UI:
        - def __init__(self, item_ui)：构造函数
        - def init(self)：连接按钮事件
        - def prepare(self)：计算所有用户查询的单词的位置信息
        - def next_word(self)：高亮下一个搜索结果
        - def count(self)：计数

    - def substitute(self)：替换当前高亮的单词
    - def substitute_all(self)：替换所有符合条件的单词
- Cal_Words_Freq.py：计算词频并返回含有词频信息的词典
- Inverted_Index：创建索引文件并返回索引

3. 详细设计

3.1 构造哈夫曼树

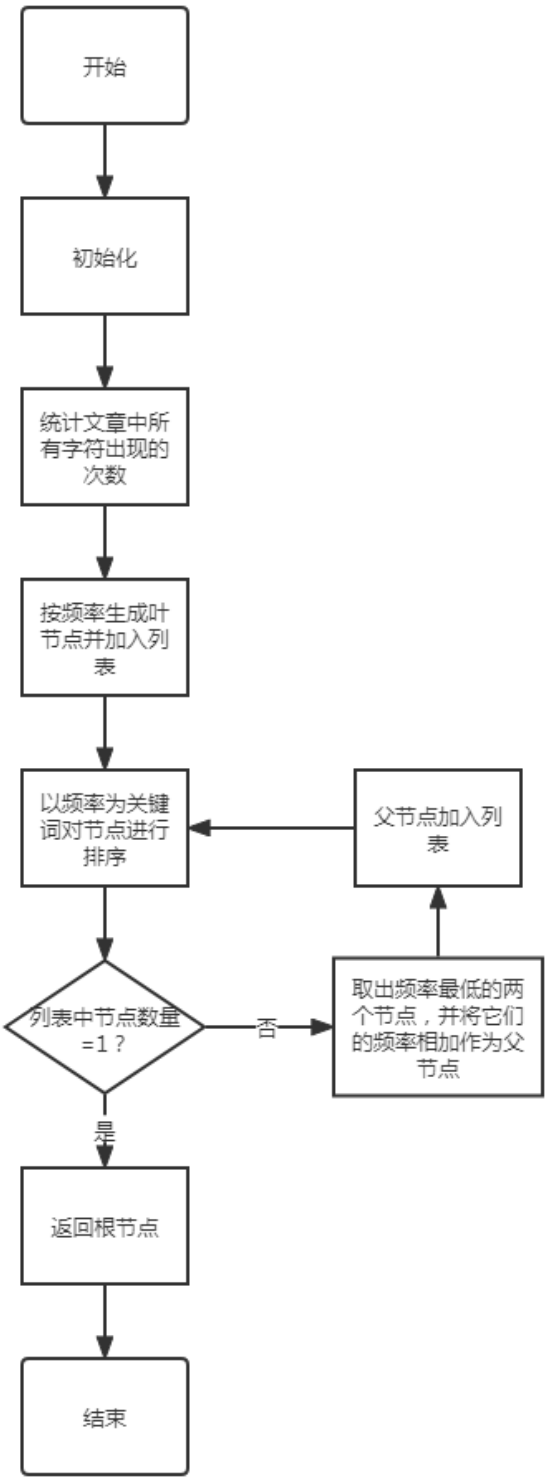

3.2 KMP 算法

3.2.1 获取 next 表

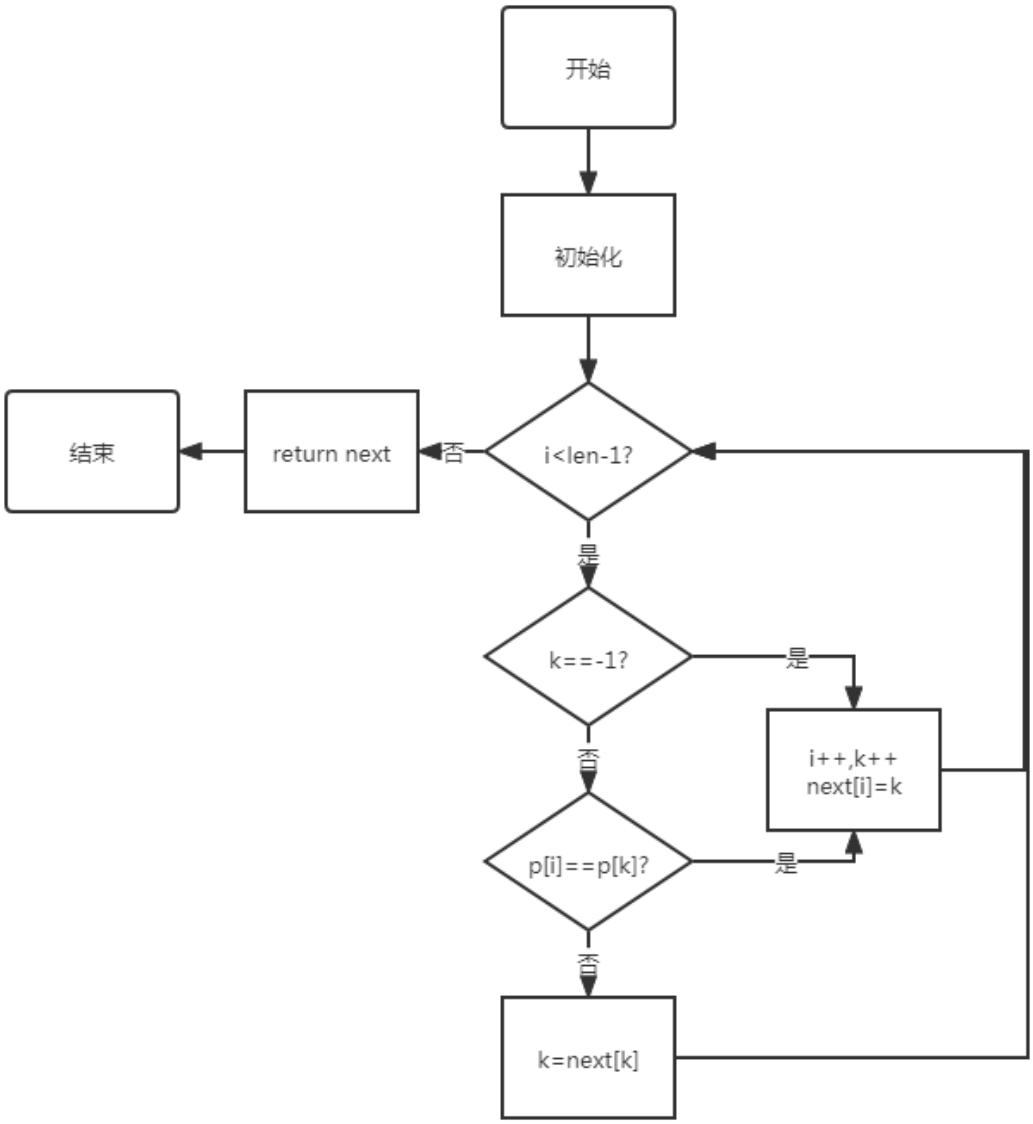

3. 2. 2 文本匹配

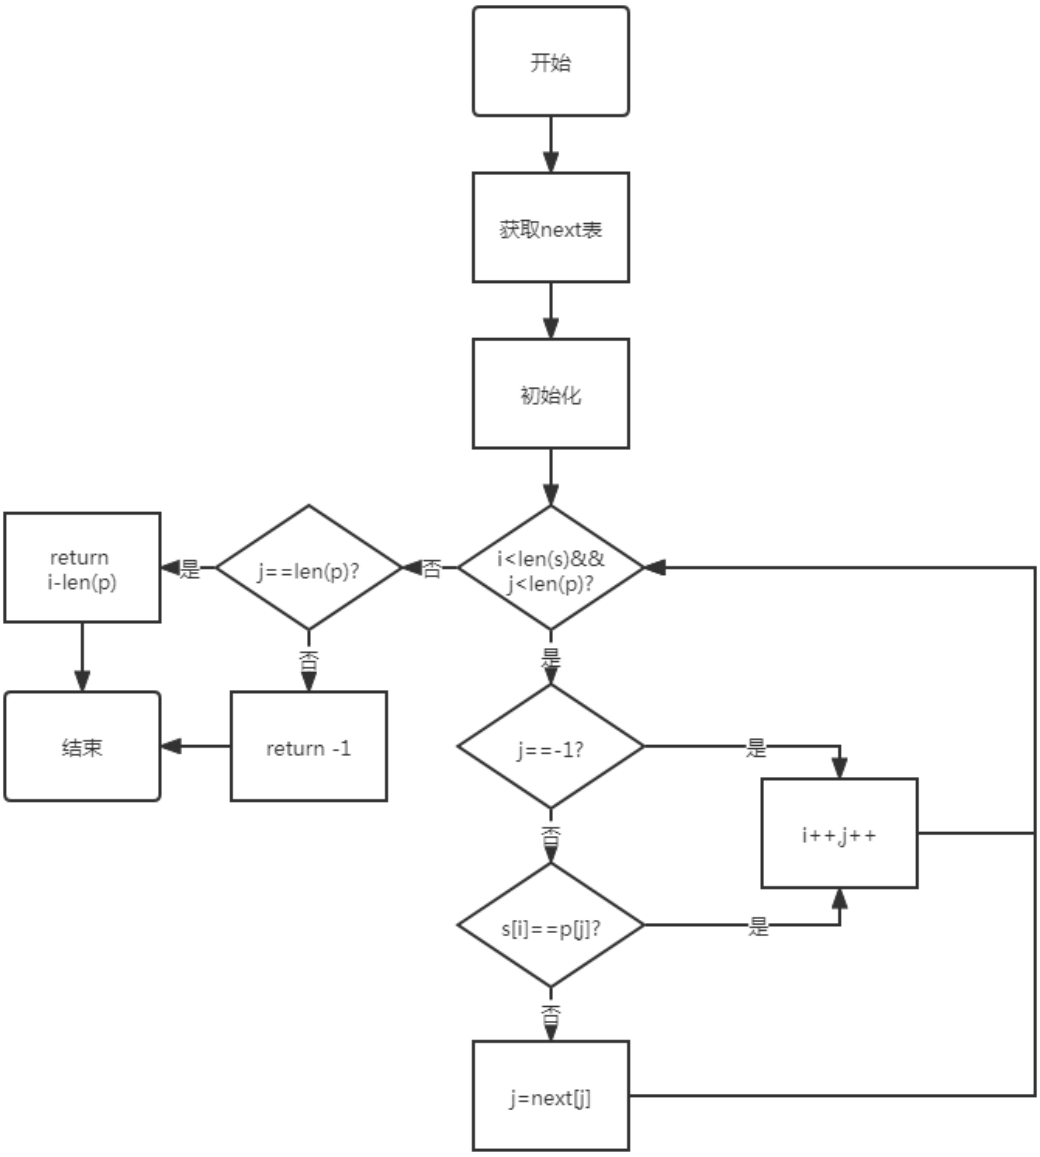
开始
获取next表
初始化
i<len(s)&&
j<len(p)?
否
j==len(p)?
是
return
i-len(p)
否
return -1
结束
是
j==-1?
是
i++j++
否
s[i]==p[j]?
是
否
j=next[j]

3.3 创建索引

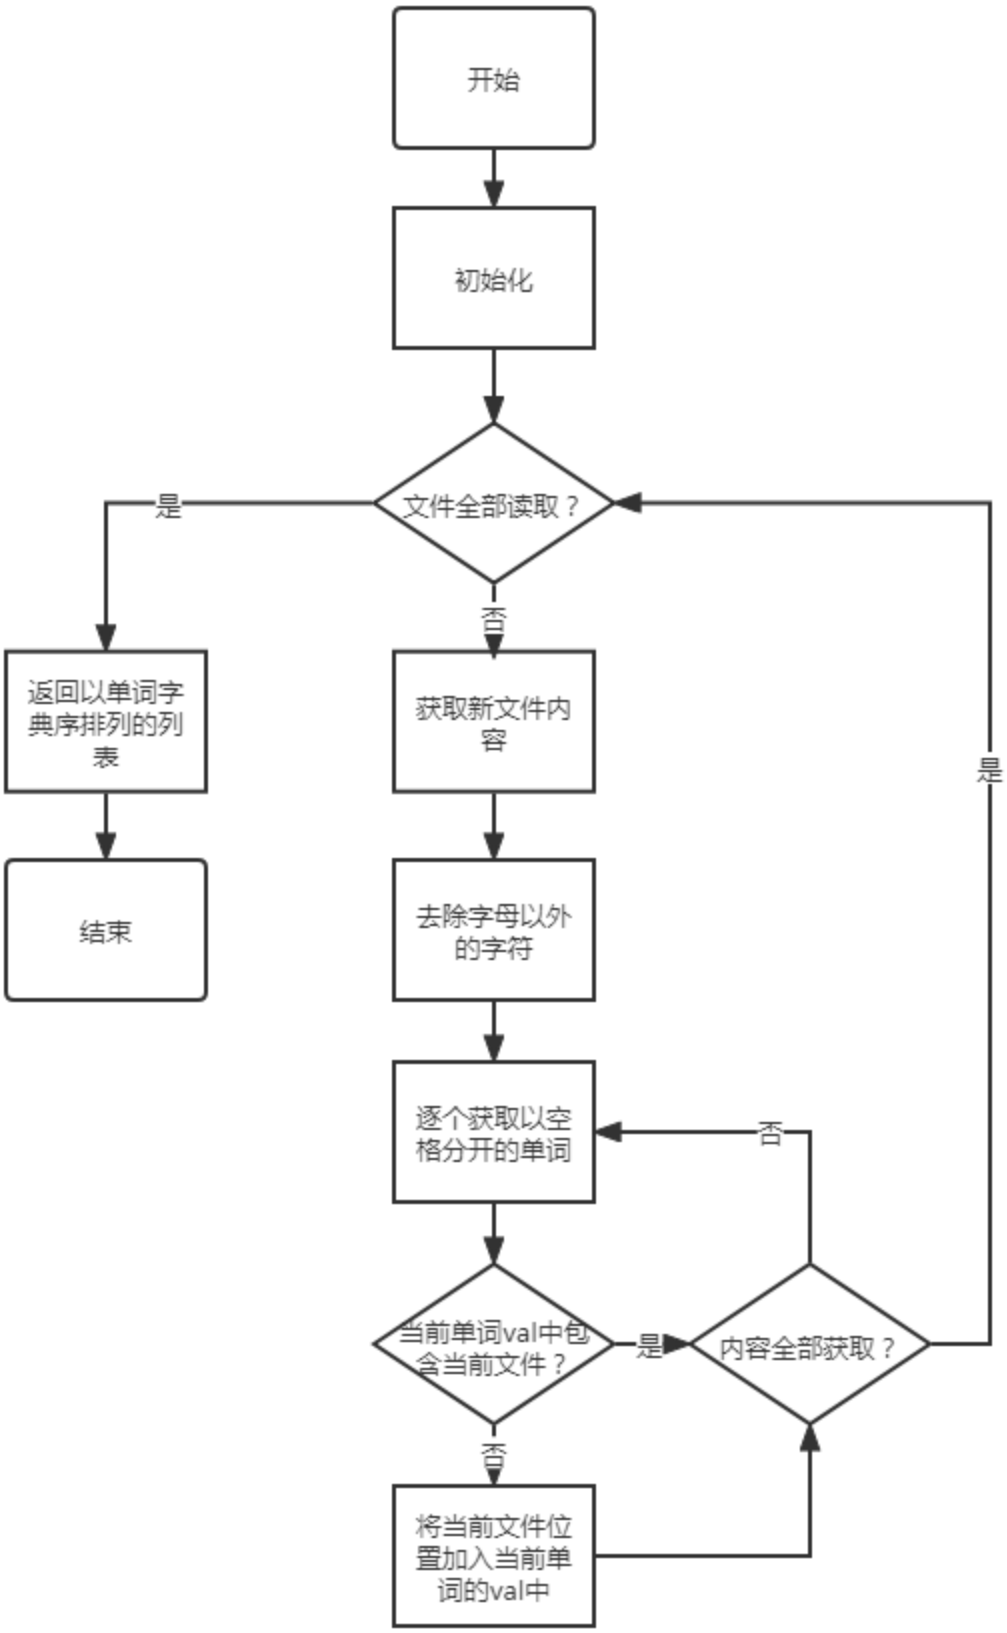
开始
初始化
文件全部读取？
是
否
返回以单词字典序排列的列表
结束
获取新文件内容
去除字母以外的字符
逐个获取以空格分开的单词
否
当前单词val中包含当前文件？
是
内容全部获取？
是
否
将当前文件位置加入当前单词的val中

3.4 统计词频

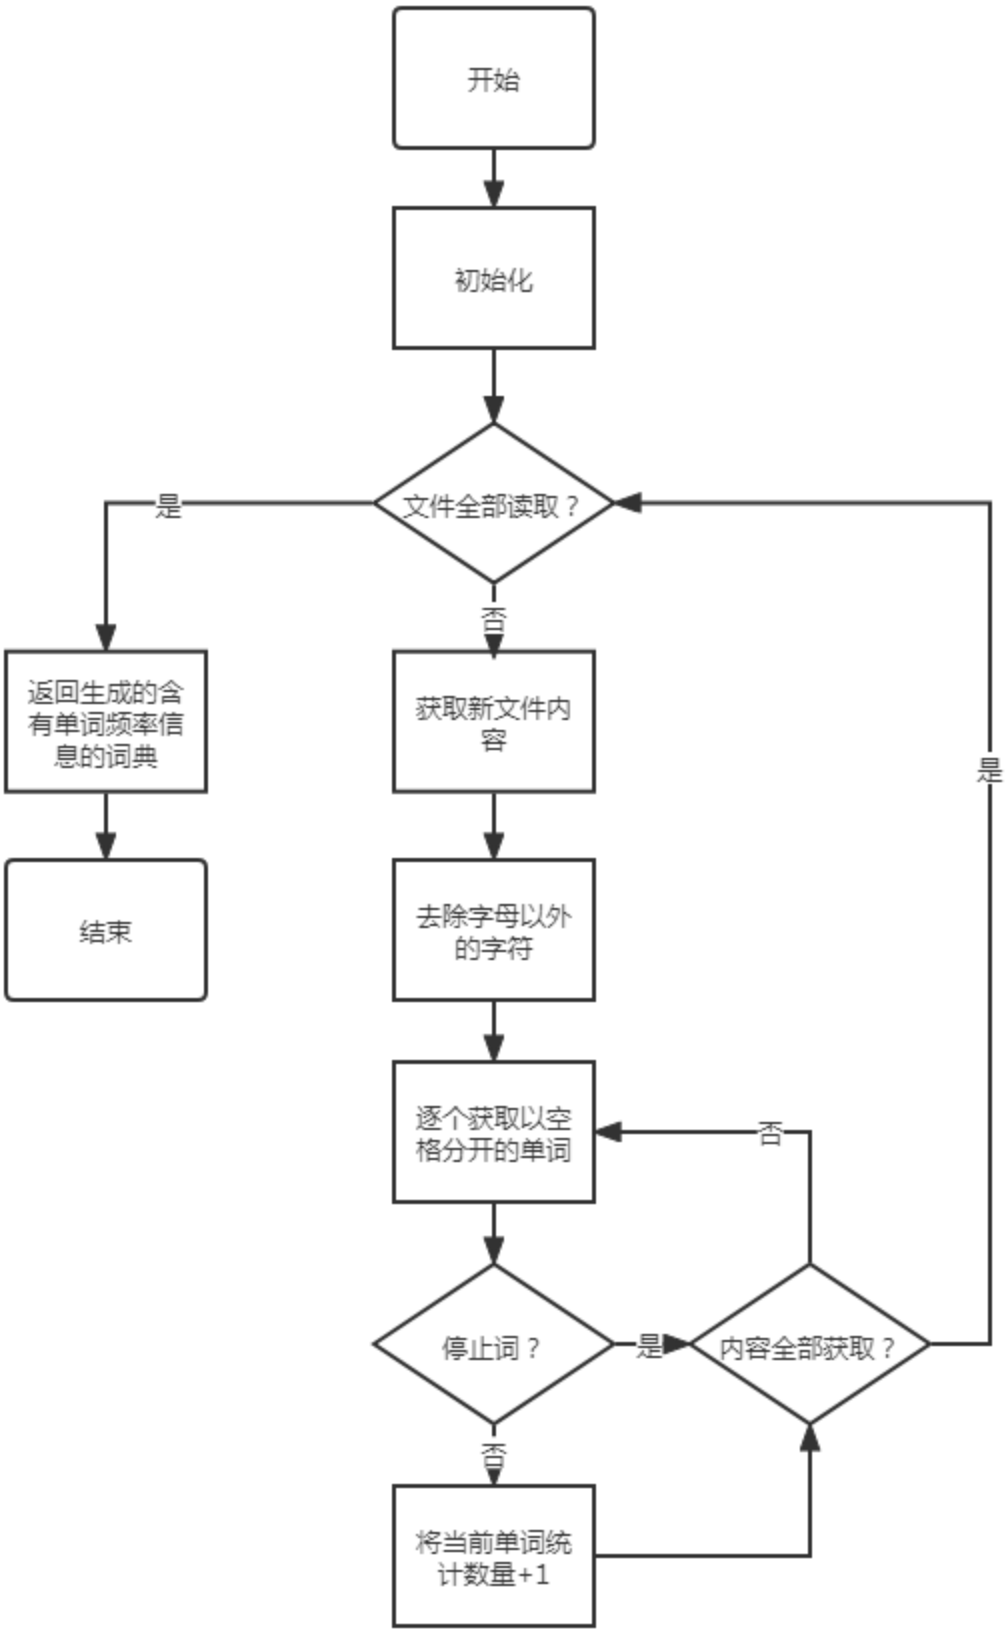
开始
初始化
文件全部读取？
是
否
返回生成的含有单词频率信息的词典
结束
获取新文件内容
去除字母以外的字符
逐个获取以空格分开的单词
否
停止词？
是
内容全部获取？
是
否
将当前单词统计数量+1

3.5 高级搜索

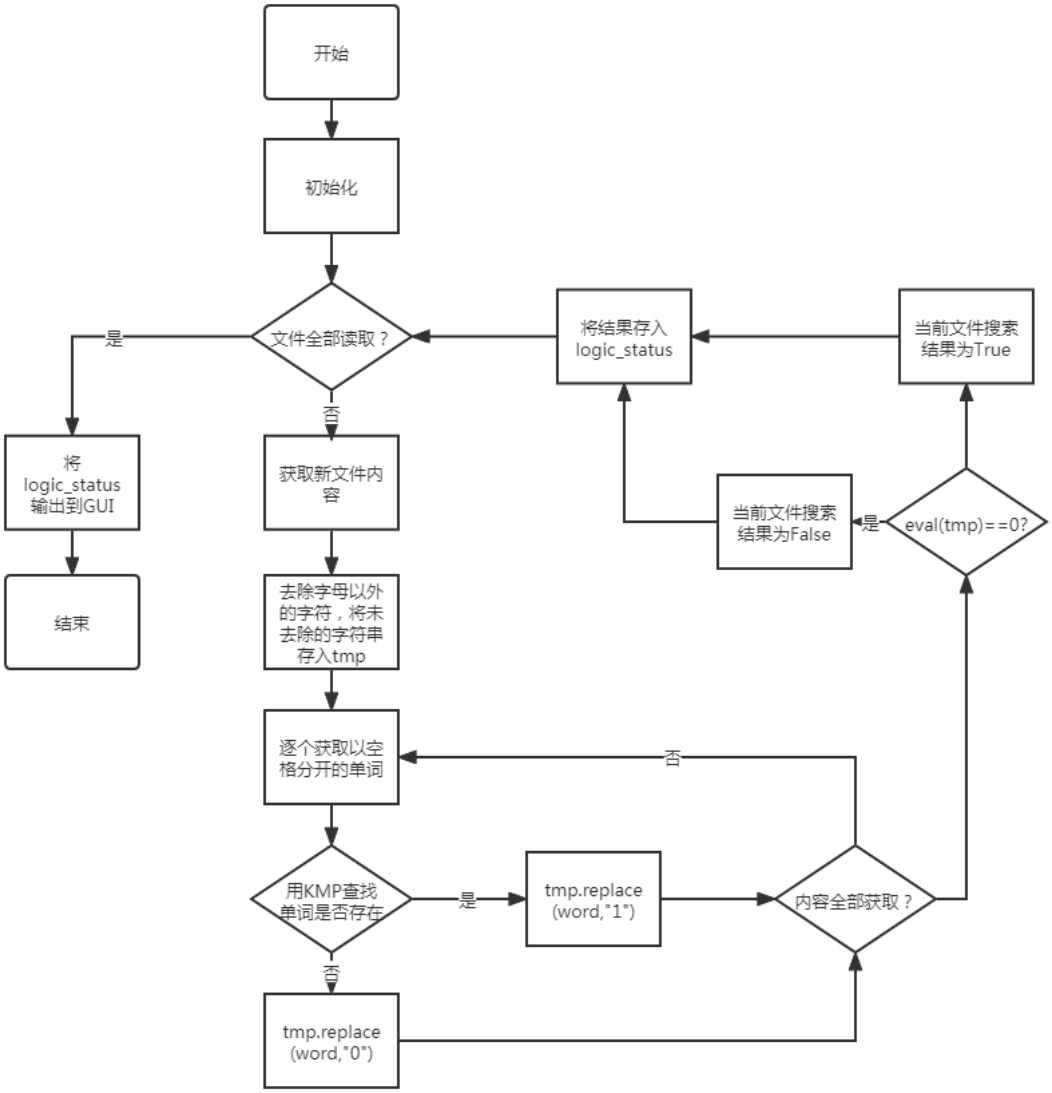

3.6 UI 设计

3.6.1 主界面

搜索

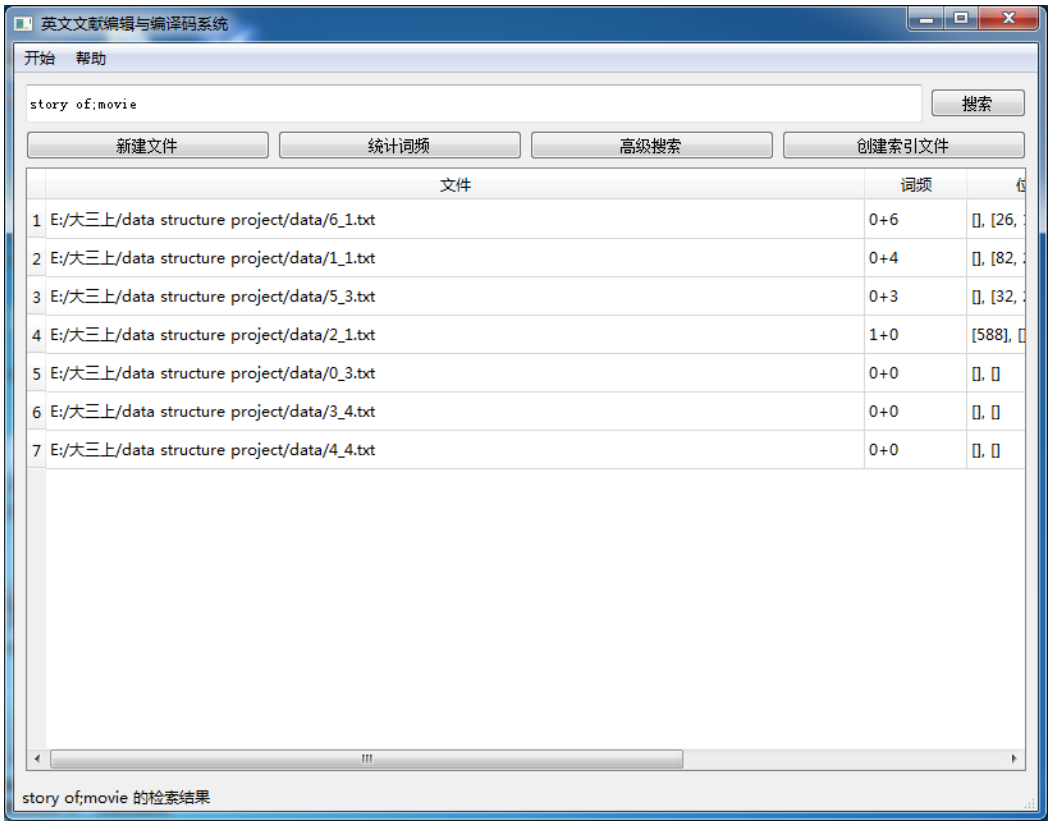

高级搜索

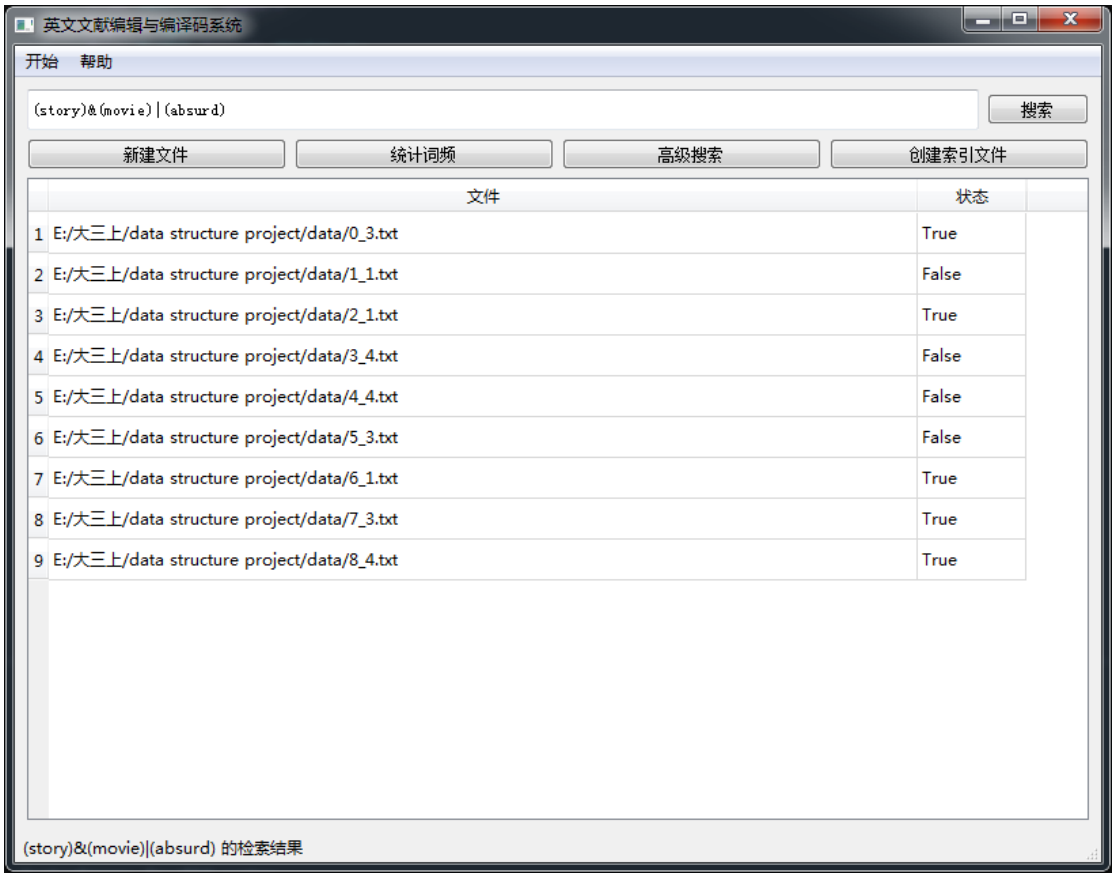

3.6.2 item 窗口

高亮

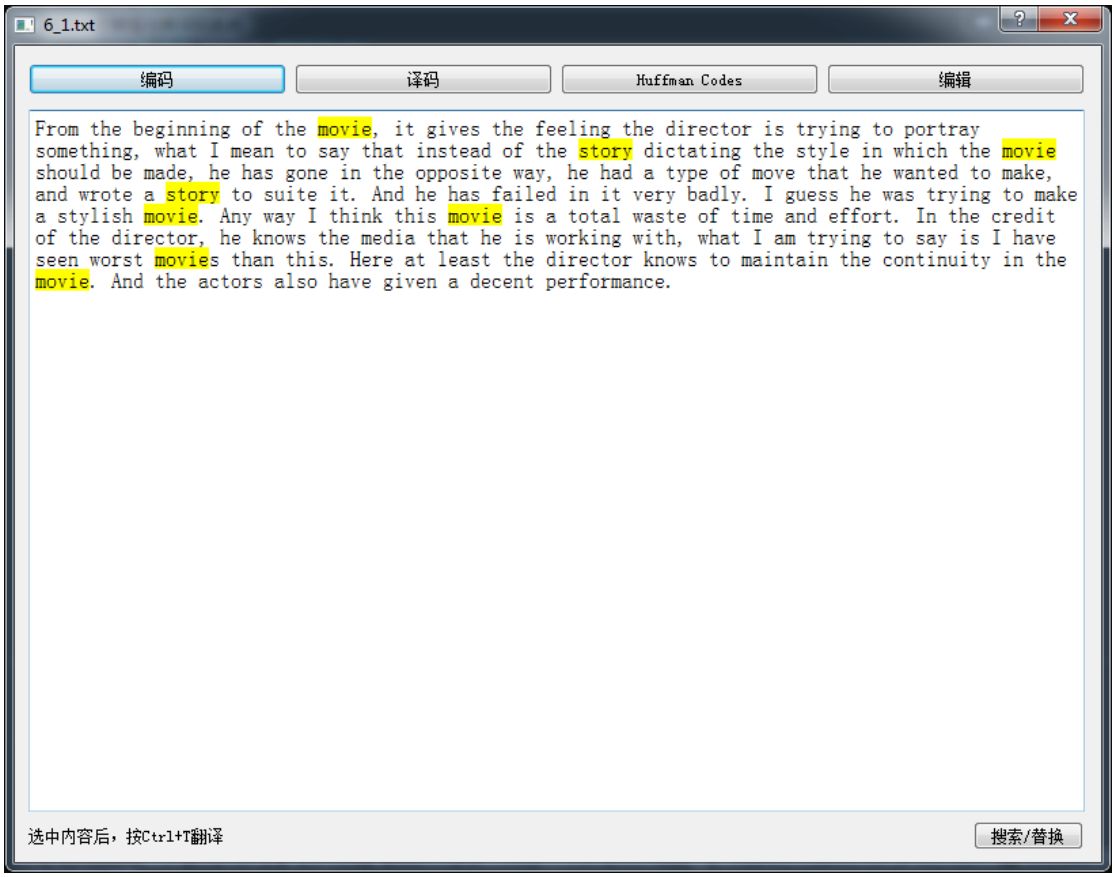
6_1.txt
编码
译码
Huffman Codes
编辑
From the beginning of the movie, it gives the feeling the director is trying to portray something, what I mean to say that instead of the story dictating the style in which the movie should be made, he has gone in the opposite way, he had a type of move that he wanted to make, and wrote a story to suite it. And he has failed in it very badly. I guess he was trying to make a stylish movie. Any way I think this movie is a total waste of time and effort. In the credit of the director, he knows the media that he is working with, what I am trying to say is I have seen worst movies than this. Here at least the director knows to maintain the continuity in the movie. And the actors also have given a decent performance.
选中内容后，按Ctrl+T翻译
搜索/替换

查找下一个

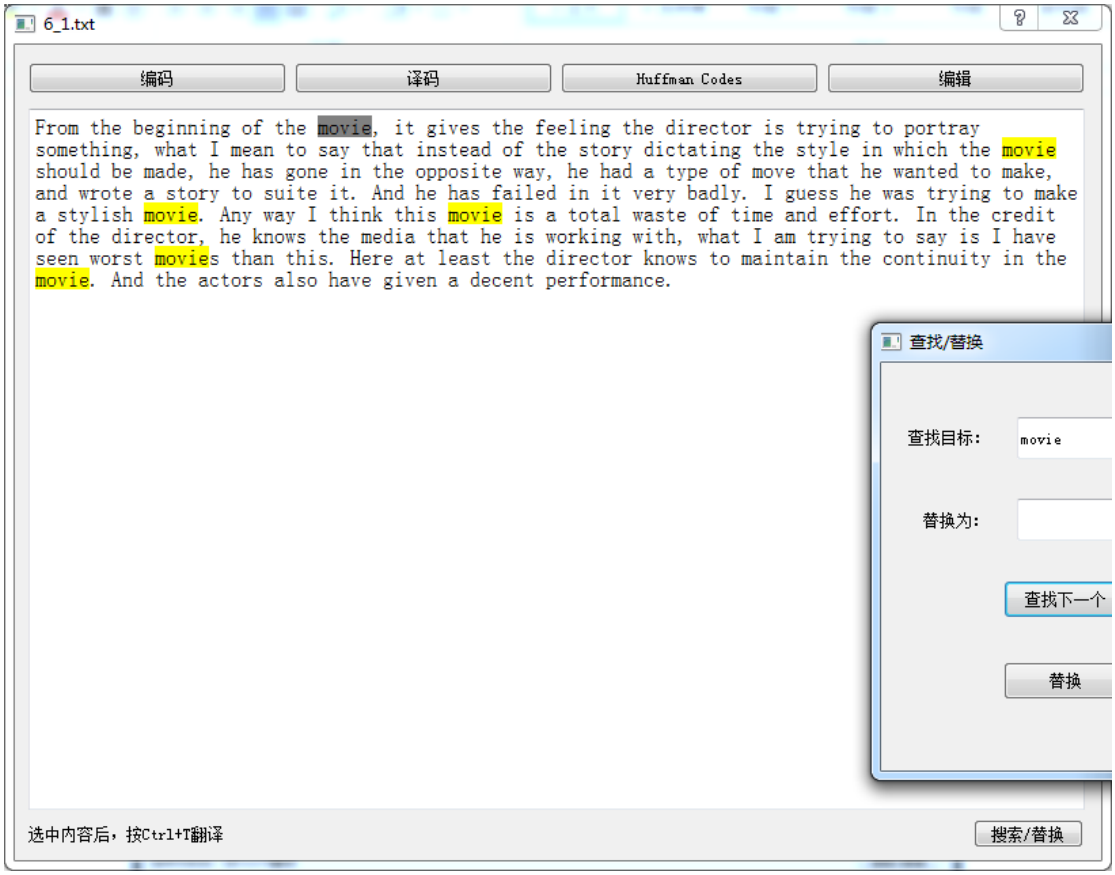
6_1.txt
编码
译码
Huffman Codes
编辑
From the beginning of the movie, it gives the feeling the director is trying to portray something, what I mean to say that instead of the story dictating the style in which the movie should be made, he has gone in the opposite way, he had a type of move that he wanted to make, and wrote a story to suite it. And he has failed in it very badly. I guess he was trying to make a stylish movie. Any way I think this movie is a total waste of time and effort. In the credit of the director, he knows the media that he is working with, what I am trying to say is I have seen worst movies than this. Here at least the director knows to maintain the continuity in the movie. And the actors also have given a decent performance.
查找/替换
查找目标:
movie
替换为:
查找下一个
替换
选中内容后，按Ctrl+T翻译
搜索/替换

翻译

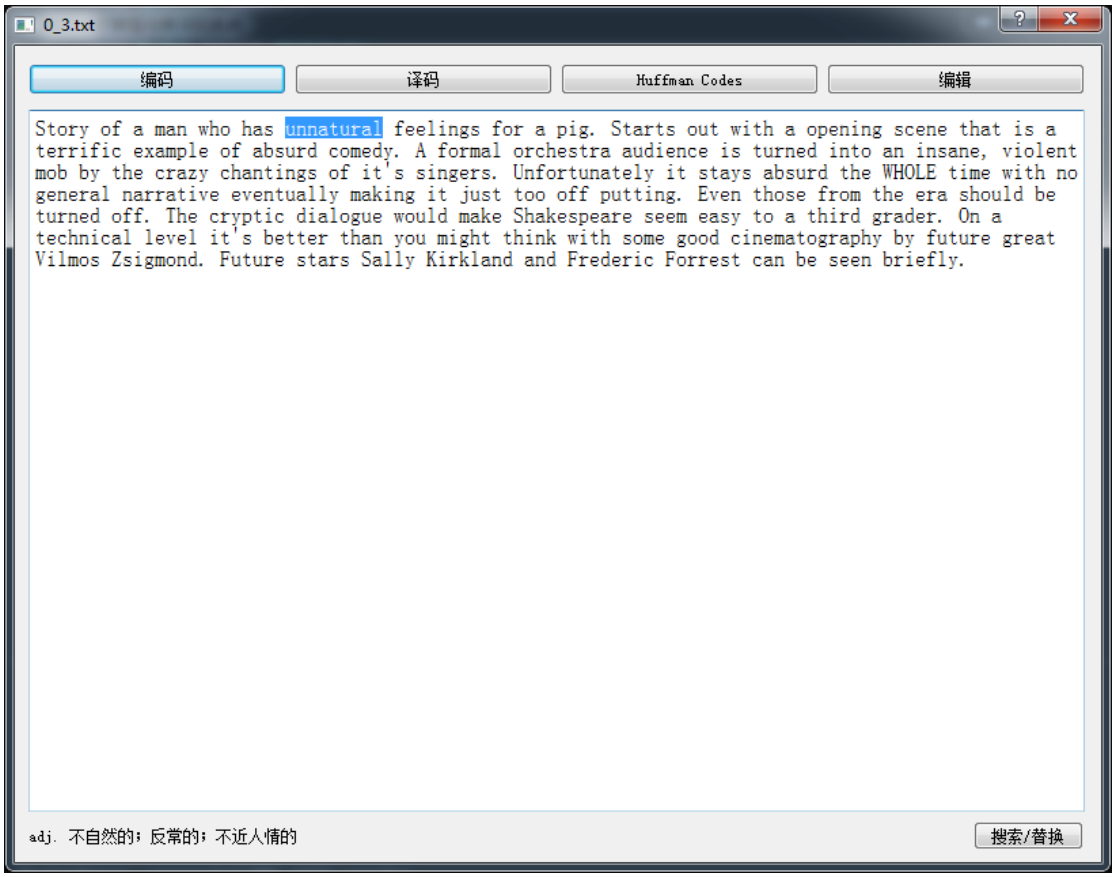

4. 测试

4.1 正确运行程序的用例

所有英文文本(如给定的data文件夹中的所有文本)都可以正确运行该系统所有功能。另外，以空格分隔词语的中文文本也可以正常运行。

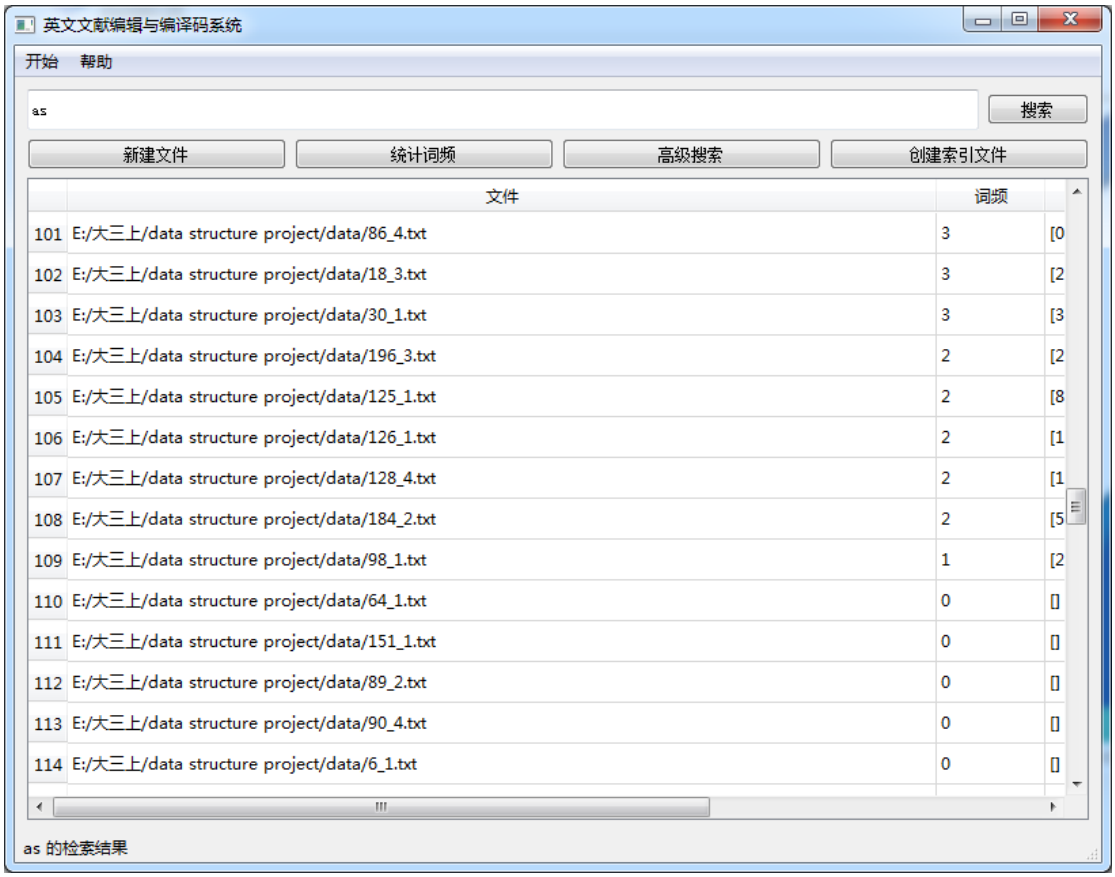

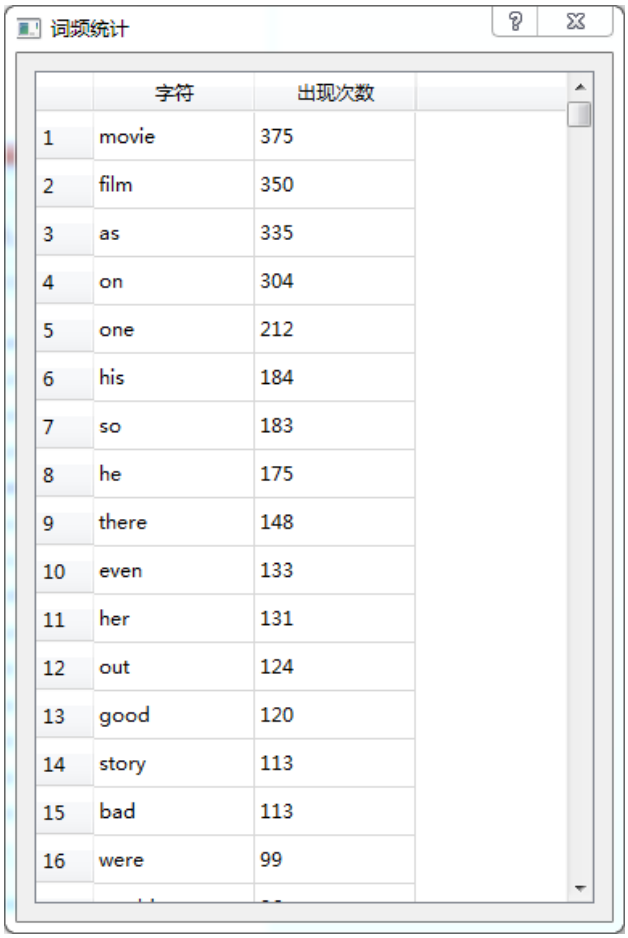

	字符	出现次数
1	movie	375
2	film	350
3	as	335
4	on	304
5	one	212
6	his	184
7	so	183
8	he	175
9	there	148
10	even	133
11	her	131
12	out	124
13	good	120
14	story	113
15	bad	113
16	were	99

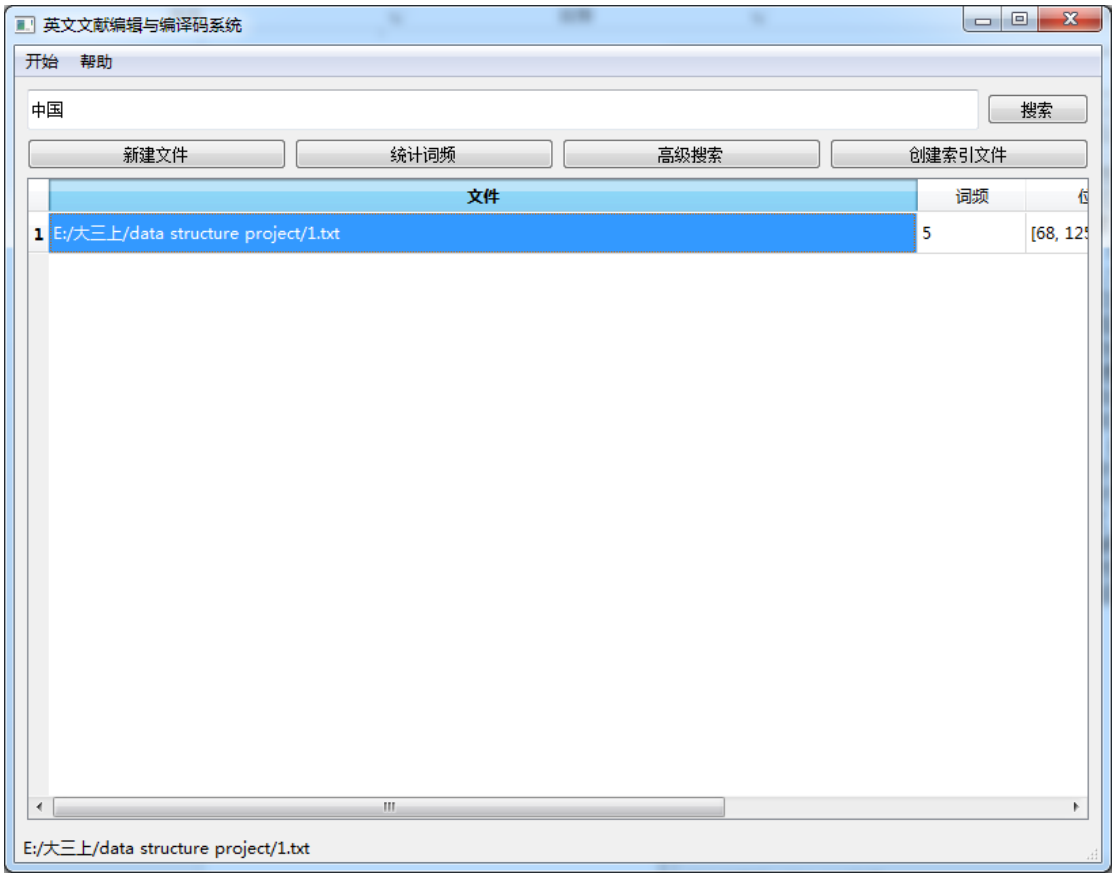
英文文献编辑与编译码系统
开始
帮助
中国
搜索
新建文件
统计词频
高级搜索
创建索引文件
文件
词频
1
E:/大三上/data structure project/1.txt
5
[68, 125
E:/大三上/data structure project/1.txt

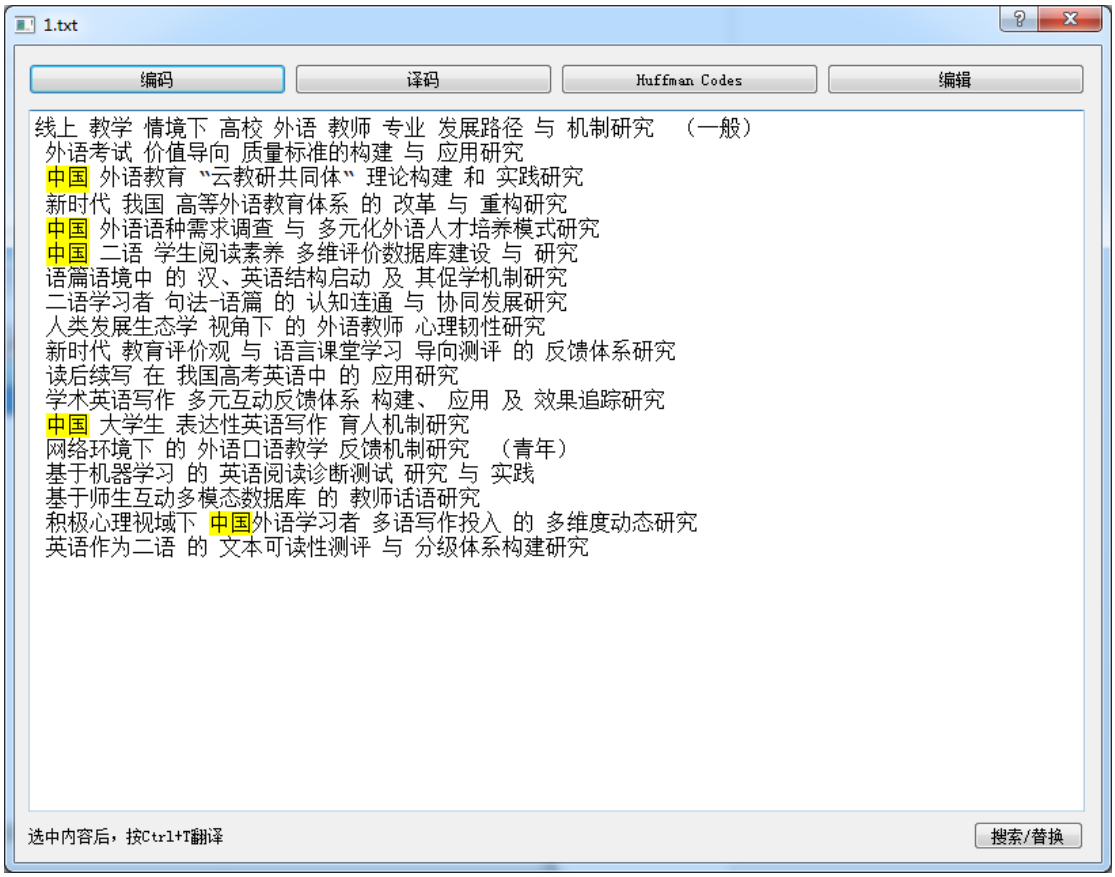
1.txt
编码
译码
Huffman Codes
编辑
线上 教学 情境下 高校 外语 教师 专业 发展路径 与 机制研究 （一般）
外语考试 价值导向 质量标准的构建 与 应用研究
中国 外语教育 "云教研共同体" 理论构建 和 实践研究
新时代 我国 高等外语教育体系 的 改革 与 重构研究
中国 外语语种需求调查 与 多元化外语人才培养模式研究
中国 二语 学生阅读素养 多维评价数据库建设 与 研究
语篇语境中 的 汉、英语结构启动 及 其促学机制研究
二语学习者 句法-语篇 的 认知连通 与 协同发展研究
人类发展生态学 视角下 的 外语教师 心理韧性研究
新时代 教育评价观 与 语言课堂学习 导向测评 的 反馈体系研究
读后续写 在 我国高考英语中 的 应用研究
学术英语写作 多元互动反馈体系 构建、 应用 及 效果追踪研究
中国 大学生 表达性英语写作 育人机制研究
网络环境下 的 外语口语教学 反馈机制研究 （青年）
基于机器学习 的 英语阅读诊断测试 研究 与 实践
基于师生互动多模态数据库 的 教师话语研究
积极心理视域下 中国外语学习者 多语写作投入 的 多维度动态研究
英语作为二语 的 文本可读性测评 与 分级体系构建研究
选中内容后，按Ctrl+T翻译
搜索/替换

4.2 导致程序运行错误的用例

- 使用高级搜索时，出现连续括号会导致程序无法正常运行
- 搜索部分带有复数的单词时，可能导致搜索结果不够准确

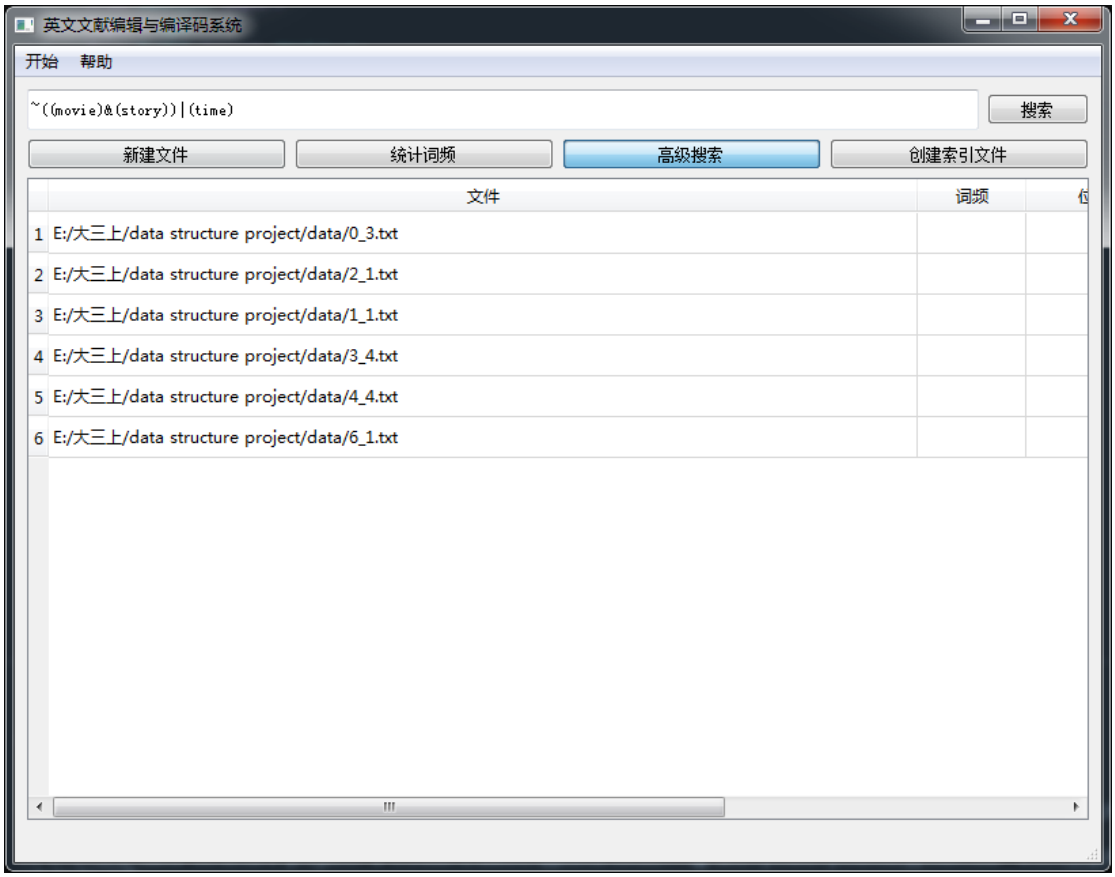
英文文献编辑与编译码系统
开始 帮助
~((movie)&(story))|(time)
搜索
新建文件
统计词频
高级搜索
创建索引文件
文件
词频
1 E:/大三上/data structure project/data/0_3.txt
2 E:/大三上/data structure project/data/2_1.txt
3 E:/大三上/data structure project/data/1_1.txt
4 E:/大三上/data structure project/data/3_4.txt
5 E:/大三上/data structure project/data/4_4.txt
6 E:/大三上/data structure project/data/6_1.txt

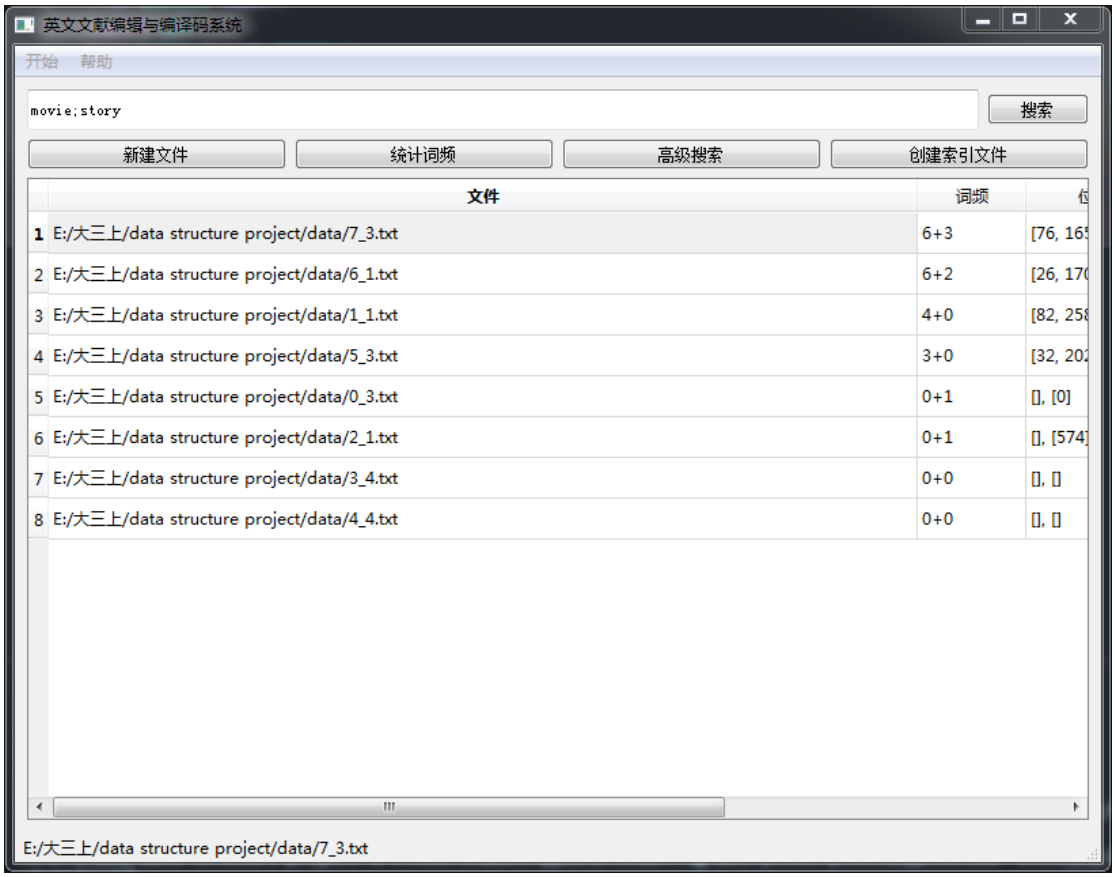
英文文献编辑与编译码系统
开始 帮助
movie;story
搜索
新建文件
统计词频
高级搜索
创建索引文件
文件
词频
1 E:/大三上/data structure project/data/7_3.txt 6+3
2 E:/大三上/data structure project/data/6_1.txt 6+2
3 E:/大三上/data structure project/data/1_1.txt 4+0
4 E:/大三上/data structure project/data/5_3.txt 3+0
5 E:/大三上/data structure project/data/0_3.txt 0+1 [], [0]
6 E:/大三上/data structure project/data/2_1.txt 0+1 [], [574]
7 E:/大三上/data structure project/data/3_4.txt 0+0 [], []
8 E:/大三上/data structure project/data/4_4.txt 0+0 [], []
E:/大三上/data structure project/data/7_3.txt

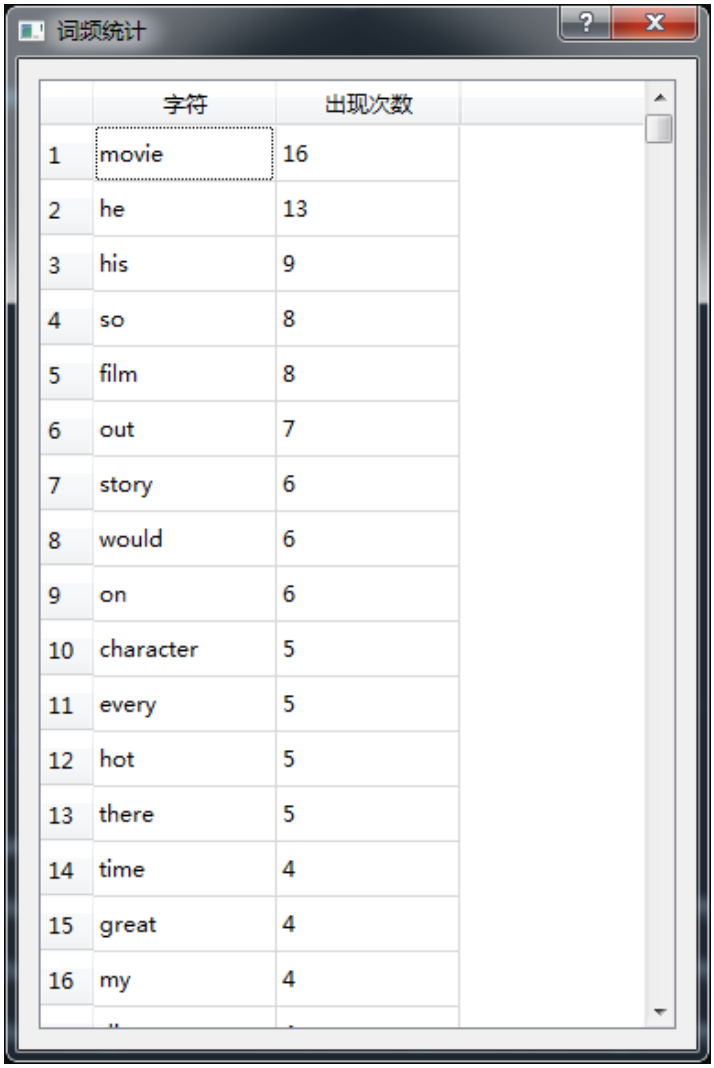
词频统计
字符
出现次数
1 movie 16
2 he 13
3 his 9
4 so 8
5 film 8
6 out 7
7 story 6
8 would 6
9 on 6
10 character 5
11 every 5
12 hot 5
13 there 5
14 time 4
15 great 4
16 my 4

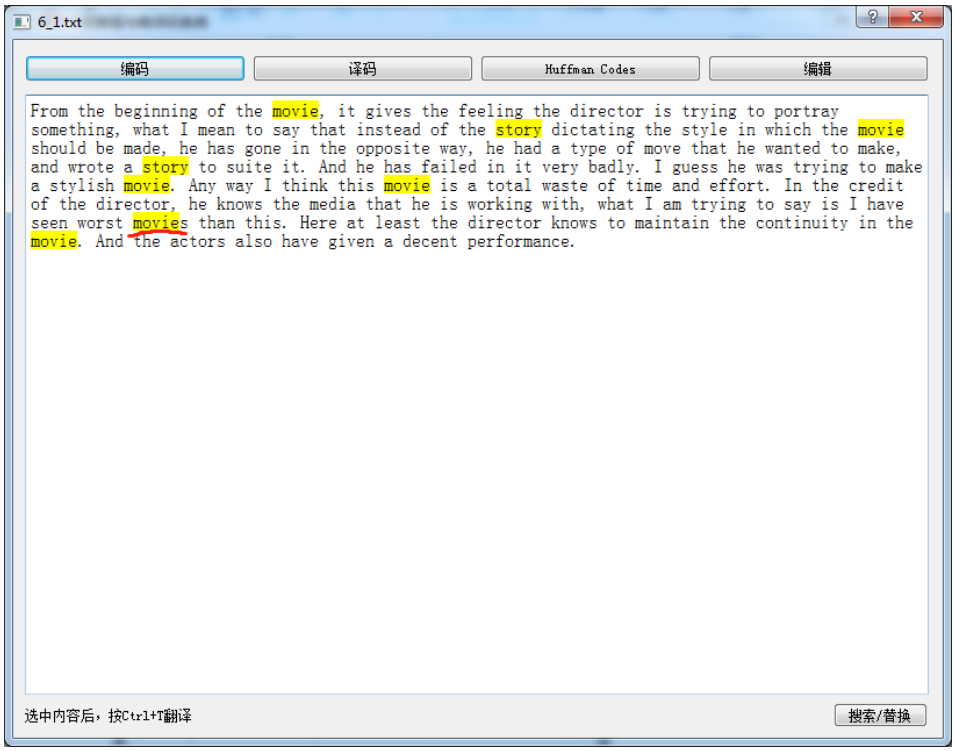
6_1.txt
编码
译码
Huffman Codes
编辑
From the beginning of the movie, it gives the feeling the director is trying to portray something, what I mean to say that instead of the story dictating the style in which the movie should be made, he has gone in the opposite way, he had a type of move that he wanted to make, and wrote a story to suite it. And he has failed in it very badly. I guess he was trying to make a stylish movie. Any way I think this movie is a total waste of time and effort. In the credit of the director, he knows the media that he is working with, what I am trying to say is I have seen worst movies than this. Here at least the director knows to maintain the continuity in the movie. And the actors also have given a decent performance.
选中内容后，按Ctrl+T翻译
搜索/替换

5. 总结与提高

当我刚拿到题目要求的时候，我的内心是抗拒的。倒不是因为算法很难实现，无论是 KMP、Huffman 编码还是倒排索引，在上学期的算法课和之前的算法竞赛都学习过。最让我头疼的是用户界面的实现，上一次用 Java 实现用户界面的过程实在是很折磨。经过一番调查和研究，最终我决定用 Python 的 PyQt5 库实现用户界面，QtDesigner 可视化的编程方式真的很适合我。

本以为数据结构和算法部分进展会很顺利，没想到碰到了不少问题。首先是在 KMP 匹配时遇到的大小写问题。原句可能会有首字母大写的情况，这样的话就会让本来匹配的单词不再匹配。我的处理方式是把全部文本变为小写。其次，原句中的各种标点符号会对词语分割产生影响。经过各种测试后，我在预处理阶段把文本中的标点符号全部用 replace 函数去掉。最后就是对于单词复数的处理。我想了很多种方法，比如去除末尾 s、复数和单数分别处理，都达不到很满意的效果，这也让我看到了 KMP 算法的局限性。如果有更多的时间，我回去更加深入的研究这个问题。

到了最麻烦的图形界面部分，最开始遇到的问题，每个程序进程只能运行一个 MainWindow 类，在不知道的情况下打开多窗口一直报错，后来得以解决。随之而来的是文本的高亮问题，后来查到的方法是在文本框中控制虚拟光标选中目标然后更改其格式，以达到高亮的效果。

在完成大部分功能要求后，我开始想其他扩展功能。翻译功能是个很棒的想法。起初，我想建立本地的词典资源文件，通过索引或二分法进行查找，但后来发现很难找到好用的文本词典资源。于是转而使用爬虫进行翻译，还好效果不错，只是需要联网。

另一个扩展功能本来是想通过自然语言识别来对文本进行一些因果分析，学院的 Keystone 课程我做的就是相关内容的实现。很遗憾，我们的成果并不足以分析英文文章的因果关系，只能对中文文本进行分析，且准确率并不高，最终我放弃了这个想法。

在整个编写课设的过程中，我主要学习了 PyQt5 的使用，对于以后编写简单的图形用户界面非常有帮助。同时，我也复习巩固了哈夫曼树和 KMP 算法，原来都是在竞赛中应对特定题目，这是第一次应用到自己的项目中，还是很有成就感的。我对于 Python 中 list、dict 的使用也更加熟练。不得不感叹，相比较于我常用的 C 语言，python 的很多集成功能实在是非常方便，随着对 Python 的深入了解，我越来越喜欢上了这个语言。

对于自己完成课设情况的评价，我觉得我的完成度还不错，实现了老师要求的基础和拓展功能。如果要改进的话，可能更多会把注意力放在如何把各种功能的表现形式变得更美观。非常感谢这种独自完成整个项目的机会，让我在各方面都有所提升，也很有成就感。我想，我收获的不仅是一个简单的文献系统，更重要的是，我收获了这种不断 debug、敲代码最后终于实现需求的过程，相信这对于我将来的工作会有很大帮助。